THÈME 6 Inférence bayésienne

Manuel p. 273-276

I. Introduction

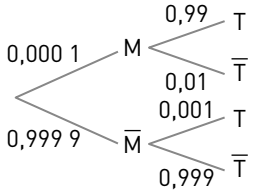
Ce thème permet d'approfondir la notion de probabilité conditionnelle en étudiant ce qu'on appelle l'inversement d'une condition. La formule de Bayes a longtemps été appelée formule de probabilité des causes. Elle permet en effet de remonter le temps, c'est-à-dire de calculer la probabilité d'une cause sachant celle de sa conséquence. On approfondira aussi des notions propres à la médecine telles que celles de spécificité et sensibilité, ainsi que les vrais/faux positifs/négatifs.

II. Corrigés des TP et des problèmes thématiques

1. Test de dépistage d'une maladie

- **Durée estimée :** 15 min
- **Objectif :** Découvrir la formule de Bayes.

1.



2. $p(M) = 0{,}000\,1$, $p_M(T) = 0{,}99$ et $p_{\overline{M}}(T) = 0{,}001$

3. D'après les probabilités totales :

$$\begin{aligned} p(T) &= p(M) \times p_M(T) + p(\overline{M}) \times p_{\overline{M}}(T) \\ &= 0{,}000\,1 \times 0{,}99 + 0{,}999\,9 \times 0{,}001 \\ &= 0{,}001\,098\,9 \end{aligned}$$

4. On a : $p_T(M) = \dfrac{p(T \cap M)}{p(T)} = \dfrac{p(M) \times p_M(T)}{p(T)}$

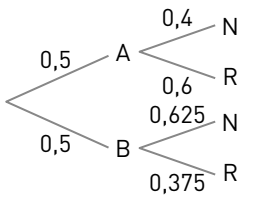
5. $p_T(M) = \dfrac{0{,}000\,1 \times 0{,}99}{0{,}001\,098\,9} = 0{,}090\,09$

6. Non, il ne faut pas commercialiser ce test car il n'est pas assez fiable.

2. De quelle urne vient la boule ?

- **Durée estimée :** 15 min
- **Objectif :** Utiliser la formule de Bayes.

1.



2. D'après les probabilités totales :

$$\begin{aligned} p(R) &= p(A) \times p_A(R) + p(B) \times p_B(R) \\ &= 0{,}5 \times 0{,}6 + 0{,}5 \times 0{,}375 \\ &= 0{,}487\,5 \end{aligned}$$

3. $p_R(A) = \dfrac{p(A) \times p_A(R)}{p(R)} = \dfrac{0{,}5 \times 0{,}6}{0{,}487\,5} = 0{,}615$

3. Mails indésirables

- **Durée estimée :** 25 min
- **Objectif :** Utiliser la formule de Bayes.

A ▶ Premier exemple

On commence par nommer les événements et reformuler les hypothèses de l'énoncé.
On choisit au hasard un mail dans le courrier reçu.
On note les événements suivants.

F : « Le mail est frauduleux. »

U : « Le mail contient le mot "urgent". »

On a par hypothèse :

$p(F) = 0{,}5$, $p_F(U) = 0{,}9$, $p_{\overline{F}}(U) = 0{,}1$

On détermine une probabilité conditionnelle pour répondre à la question.

$$p_U(\overline{F}) = \frac{p(\overline{F}) \times p_{\overline{F}}(U)}{p(U)}$$

Les événements F et $\overline{F}$ forment un système complet de l'univers, on peut donc appliquer la formule de la probabilité totale dans le calcul de $p(U)$.

On obtient :

$$p_U(\overline{F}) = \frac{p(\overline{F}) \times p_{\overline{F}}(U)}{0{,}5p_F(U) + 0{,}5p_{\overline{F}}(U)} = 0{,}1$$

Il y a encore une quantité non négligeable de mails qui ne sont pas frauduleux et pourtant placés dans la catégorie indésirable.

B ▶ Second exemple

On suppose ici que les événements forment un système complet de l'univers.

1. On peut alors compléter le tableau.

Collègues	Amis	Publicité
0,4	0,1	0,5
Inf. 150	**Entre 150 et 330**	**Sup. 330**
0,01	0,44	0,55

2. a) On a :

$p(\text{« connu » } \cap \text{ « pub»}) = \dfrac{199}{200} \times 0{,}5 = 0{,}497\,5$

b) Il s'agit de comparer 0,5 à la probabilité de que le mail, sachant qu'il est connu, soit indésirable et compris entre 50 et 130 caractères.

Cette dernière probabilité se calcule en utilisant la loi de probabilité conditionnelle de l'événement : « Le mail est connu ».

Aux vues des données de l'énoncé, il nous faut avancer une hypothèse d'indépendance.
Cette probabilité est donc inférieure à 5×10^{-5}.
Il est donc beaucoup plus probable de recevoir un mail publicitaire.

3. On considère un mail pris au hasard. On note :

U l'événement : « Le mail contient le mot "urgent". »
I l'événement : « Le mail est indésirable ».

a) D'après la formule des probabilités totales, on a :

$p(U) = p(U \cap I) + p(U \cap \overline{I})$

$= \dfrac{1}{800} \times 0{,}6 + 0{,}2$

$= 0{,}200\,75 \approx 0{,}2$

b) Ainsi, on obtient :

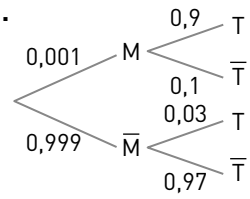
$p_U(I) = \dfrac{p(U \cap I)}{p(U)} \approx 0{,}003\,7$

Si le mail contient le mot "urgent", il est très peu probable qu'il soit indésirable.

4. Chez le médecin

- **Durée estimée :** 25 min
- **Objectif :** Découvrir les notions de spécificité et sensibilité.

1.



2. $p(T) = p(M) \times p_M(T) + p(\overline{M}) \times p_{\overline{M}}(T)$

$= 0{,}001 \times 0{,}9 + 0{,}999 \times 0{,}03 = 0{,}030\,87$

3. $p_T(M) = \dfrac{p(M) \times p_M(T)}{p(T)} = \dfrac{0{,}001 \times 0{,}9}{0{,}030\,87} \approx 0{,}029$

4. Il n'y a que peu de chance que le test soit positif.

5.

	T	$\overline{T}$	Total
M	9	1	10
$\overline{M}$	300	9 690	9 990
Total	309	9 691	10 000

6. La probabilité est : $\dfrac{9}{309} = 0{,}029$

7. a) La sensibilité est $p_M(T)$.

b) Plus un test est sensible, moins il comporte de faux négatifs, et mieux il permet d'exclure la maladie.

c) Ici $p_M(T) = \dfrac{9}{10} = 0{,}9$

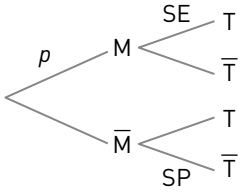
8. a) La spécificité est : $p_{\overline{M}}(\overline{T})$.

b) Plus un test est spécifique, moins il occasionne de faux positifs, et mieux il permet d'affirmer la maladie.

c) Ici $p_{\overline{M}}(\overline{T}) = \dfrac{9\,690}{9\,990} = 0{,}97$

9. Ces deux valeurs sont interdépendantes : l'augmentation de l'une se fait toujours au détriment de l'autre.

10. On a, en fait, l'arbre :



a) $VPP = p_T(M) = \dfrac{p(M) \times p_M(T)}{p(T)}$

$$= \frac{p \times SE}{p \times SE + (1-p) \times (1-SP)}$$

et $VPN = p_{\overline{T}}(\overline{M}) = \dfrac{p(\overline{M}) \times p_{\overline{M}}(\overline{T})}{p(\overline{T})}$

$$= \frac{(1-p) \times SP}{p \times (1-SE) + (1-p) \times SP}$$

b) $VPP = \dfrac{9}{309} = 0{,}029$

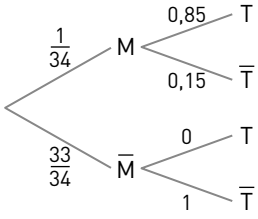
et $VPN = \dfrac{9\,690}{9\,691} = 0{,}999\,897$

5. D'autres maladies

- **Durée estimée :** 15 min
- **Objectif :** utiliser le TP 4.

A ▶ La mucoviscidose

1.



2. $p_{\overline{T}}(M) = \dfrac{p(M) \times p_M(\overline{T})}{p(\overline{T})} = \dfrac{\frac{1}{34} \times 0{,}15}{\frac{1}{34} \times 0{,}15 + \frac{33}{34} \times 1} = 0{,}004\,5$

B ▶ L'appendicite

1.

	Appendicite	**Pas d'appendicite**	**Total**
Échographie positive	235	20	255
Échographie négative	75	510	585
Total	310	530	840

2. $SP = \dfrac{510}{510 + 20} = 0{,}96$

ce qui signifie que lorsque le patient ne souffre pas d'une appendicite, il y a 96 % de chance que l'échographie soit négative.

3. $SE = \dfrac{235}{235 + 75} = 0{,}76$

ce qui signifie que lorsque le patient souffre d'une appendicite, il y a 76 % de chance que l'échographie soit positive.

4. $VPP = \dfrac{235}{235 + 20} = 0{,}92$

ce qui signifie que si l'échographie est positive, il y a 92 % de chance que le patient souffre d'une appendicite.

5. $VPN = \dfrac{510}{510 + 75} = 0{,}87$

ce qui signifie qu'il y a 87 % ce chance qu'un patient pour lequel l'échographie est négative ne présente pas d'appendicite.