THÈME 7 Répétitions d'expériences indépendantes, échantillonnage

Manuel p. 277-281

I. Introduction

Ce thème, très lié au chapitre 7 sur les lois discrètes, est l'occasion de mettre en pratique les notions qui y sont abordées dans des cas concrets proposés par le programme (tirages de boules dans une urne, tests d'hypothèse, problème de surréservation, réflexion autour des sondages), en particulier grâce aux outils numériques (programmation en Python et tableur).

La loi binomiale, nouveauté du programme de Terminale, tient naturellement une place importante dans ce thème mais il y est également question de la loi des grands nombres (pas formellement, mais intuitivement), vue en Première, dans les TP plus centrés sur la notion d'échantillonnage.

Les sondages en particulier tiennent une place importante dans ce thème puisqu'ils font l'objet des trois derniers TP, dans lesquels on en interrogera différents aspects (conditions de réalisation, types de suffrages, marge d'erreur).

II. Corrigés des TP et des problèmes thématiques

1. TP Simulation de variable aléatoire, comportement des moyennes d'échantillons

- **Durée estimée :** 55 min
- **Objectif :** Simuler des variables aléatoires.

A ▶ Simulation d'une variable aléatoire

1.
```
import math
import random
def moyenne(L):
    return sum(L)/len(L)
```

2.
```
def ecart_type(L):
    m=moyenne(L)
    L2=[]
    for i in L:
        L2.append((i-m)**2)
    return math.sqrt(sum(L)/len(L))
```

3.
```
def simul_bernou(p):
    if random.random()<=p:
        x=1
    else:
        x=0
    return x
```

4. La fonction renvoie la somme des éléments de la liste qui ne contient que des 0 ou des 1 c'est-à-dire qu'elle renvoie le nombre de 1.
Autrement dit, le nombre de succès quand on réalise n fois une épreuve de Bernoulli de paramètre p simulée par **`simul_bernou(p)`**.

5. a) La loi uniforme sur [1 ; n + 1[.

b) Pour tout k entre 1 et n, la probabilité que **`n*random.random()+1`** soit dans [k ; k + 1[est $\frac{k+1-k}{n+1-1}=\frac{1}{n}$ puis **`n*random.random()`** simule une variable aléatoire suivant le loi uniforme sur [1 ; n + 1[.

Or si $x \in [k ; k+1[$ alors **`math.floor(x)=k`**

Donc la fonction renvoie les valeurs 1, 2, ..., n avec les probabilités $\frac{1}{n}$: elle simule une variable aléatoire suivant la loi uniforme sur {1 ; 2 ; ... ; n}.

B ▶ Avec la loi binomiale

1. a) La liste renvoyée est un échantillon de taille t d'une variable aléatoire suivant la loi binomiale de paramètres n et p.

b) Elle renvoie la liste des moyennes de N échantillons de taille t d'une variable aléatoire suivant la loi binomiale de paramètres n et p.

2. a)

```
def comparaison_binom1(N,t,n,p):
    L=serie_moyennes_binom(N,t,n,p)
    s=ecart_type(L)
    print(s)
    print(math.sqrt(n*p*(1-p))/math.sqrt(t))
```

b) Les deux valeurs affichées sont proches.

3. a)

```
def comparaison_binom2(N,t,n,p):
    L=serie_moyennes_binom(N,t,n,p)
    s=ecart_type(L)
    mu=n*p
    i=0
    for x in L:
        if abs(x-mu)<=2*s:
            i=i+1
    print(i/N>I)
```

b) On remarque qu'on obtient des proportions toujours assez proches de 0,95.

2. Tirages aléatoires avec remise

- **Durée estimée :** 30 min
- **Objectif :** Simuler un tirage avec remise dans une urne.

1.

```
import random
def urne():
    if random.randint(1,100)<=20:
        couleur="vert"
    else:
        couleur="rouge"
    return couleur
```

2. a) `[urne() for i in range(n)]`

b)

```
def echantillon(n):
    return[urne()for i in range(n)]
```

3. La variable aléatoire X donnant le rang de la première boule verte obtenue suit la loi géométrique de paramètre $\frac{20}{100} = 0{,}2$. On a $p(X > 3) = 0{,}8^3 = 0{,}512$.

4. a)

```
def premier vert():
    c=urne()
    i=1
    while c!="vert":
        c=urne()
        i=i+1
    return i

A=[premier vert() for i in range(1000)]
m=sum(A)/1000
```

b) La moyenne des rangs d'obtention de la première boule verte sur 1 000 répétitions de l'expérience consistant à tirer des boules avec remise dans cette urne jusqu'à en obtenir une verte.

c) De l'espérance de X soit 5.

Remarque : Penser à ajouter un affichage de `m`.

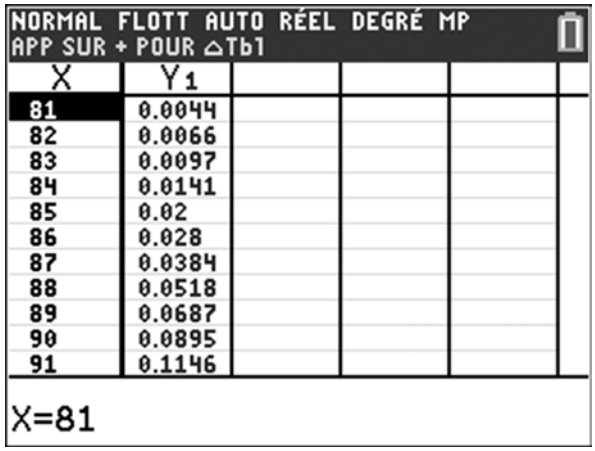
3. Vérification d'une pièce

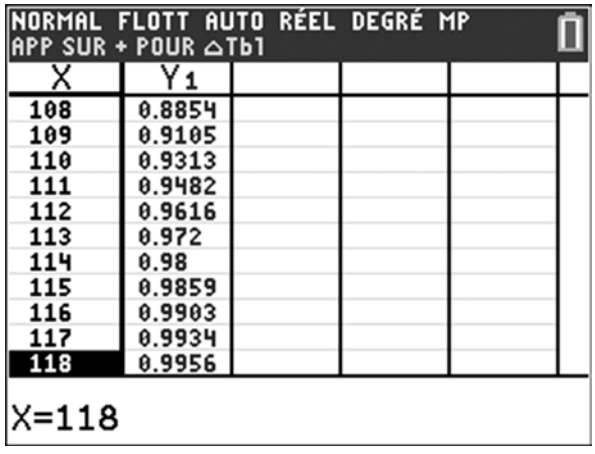
- **Durée estimée :** 30 min
- **Objectif :** Tester une pièce par construction d'un intervalle de fluctuation.

1. a) p(PILE) = 0,5.

b) X suit la loi binomiale de paramètres n = 200 et p = 0,5.

On tabule $x \mapsto p(X \leqslant x)$:





donc [86 ; 114].

c) 110 ∈ [86 ; 114] donc non.

2. Soit Y la variable aléatoire donnant le nombre de PILE obtenus quand on lance 300 fois cette pièce dans le cas où la pièce est équilibrée. Y suit la loi binomiale de paramètres $n = 300$ et $p = 0{,}5$.

On tabule $x \mapsto p(Y \leqslant x)$:

NORMAL FLOTT AUTO RÉEL DEGRÉ MP
APP SUR + POUR △Tbl

X	Y_1
130	0.0121
131	0.0162
132	0.0216
133	0.0283
134	0.0367
135	0.047
136	0.0594
137	0.0744
138	0.0921
139	0.1126
140	0.1363

X=130

NORMAL FLOTT AUTO RÉEL DEGRÉ MP
APP SUR + POUR △Tbl

X	Y_1
160	0.8874
161	0.9079
162	0.9256
163	0.9406
164	0.953
165	0.9633
166	0.9717
167	0.9784
168	0.9838
169	0.9879
170	0.9911

X=170

Donc un intervalle de fluctuation centré de Y au seuil de 95 % est [133 ; 167].

Comme Ben a fait la vaisselle 173 fois sur 300 et $173 \notin [133 ; 167]$, il paraît légitime de penser que la pièce est truquée, au risque d'erreur de 5 %.

3. a) TI-83 Premium CE : Y1=binomFRép(300,X,173)

CASIO GRAPH 90+E : Y1=binomialCD(173,300,x)

NUMWORKS : f(x)=binomcdf(173,300,x)

b) On obtient :

NORMAL FLOTT AUTO RÉEL DEGRÉ MP
APP SUR + POUR △Tbl

X	Y_1
0.5	0.9967
0.51	0.9912
0.52	0.9786
0.53	0.9536
0.54	0.9088
0.55	0.838
0.56	0.7383
0.57	0.6137
0.58	0.4754
0.59	0.3396
0.6	0.2214

X=0.5

NORMAL FLOTT AUTO RÉEL DEGRÉ MP
APP SUR + POUR △Tbl

X	Y_1
0.56	0.7383
0.57	0.6137
0.58	0.4754
0.59	0.3396
0.6	0.2214
0.61	0.1306
0.62	0.0692
0.63	0.0327
0.64	0.0137
0.65	0.005
0.66	0.0016

X=0.66

c) Si on reprend le principe d'un intervalle de fluctuation centré, on est sûr que la valeur de p est compatible quand $p(Y \leqslant 173)$ est compris entre 0,025 et 0,975 ce qui est le cas quand p est entre 0,53 et 0,63.

Remarque : On peut aussi faire remarquer qu'un intervalle de fluctuation centré n'est pas forcément le plus pertinent dans ce cas où l'on teste, finalement, davantage le fait que la pièce soit truquée au désavantage de Ben, que truquée indépendamment à l'avantage de n'importe qui.

d) Dans le modèle physique utilisé, aucun côté n'est privilégié avant de réaliser l'expérience. Donc on pouvait penser à une situation d'équiprobabilité que l'on teste ensuite.

Parmi les valeurs de p possibles trouvées, aucune n'est issue d'un modèle physique et serait donc à privilégier : ce n'est pas comme cela que l'on construit un modèle en sciences.

4. On pourrait prendre la pièce et réaliser l'expérience un grand nombre de fois pour essayer de voir vers quelle valeur la fréquence se stabilise. Dans tous les cas, comme il n'y a pas de modèle physique sous-jacent permettant d'expliquer la probabilité d'obtenir PILE, cela restera une estimation.

Remarque : Un exemple célèbre d'application de la méthode scientifique est le cas des lois de la génétique que Mendel avait théorisées.
Mendel avait prédit que, selon ces lois, il obtiendrait certaines proportions de pois de différents types lors de la réalisation d'une expérience sur des plans de pois.
Ces proportions se sont vérifiées par l'expérience. Presque trop bien car elles étaient presque parfaitement égales aux probabilités attendues alors qu'elles n'auraient pas dû car Mendel n'avait pas pris certains facteurs (qui lui étaient inconnus) en compte.
Depuis, Mendel est régulièrement accusé d'avoir falsifié ses résultats mais les lois de la génétique qu'il a énoncées se sont révélées exactes et son expérience a pu être répétée par de nombreux scientifiques avec succès : c'est un des fondement de la méthode scientifique, les hypothèses doivent être testables et vérifiables par la communauté scientifique.

4. Problème de surréservation

- **Durée estimée :** 55 min
- **Objectif :** Programmer des fonctions avec la loi binomiale et les utiliser dans un cas de surréservation.

A ▶ 1. a) • **`parmi(1,1)`** renvoie **1** car $k = n$.

• **`parmi(0,1)`** renvoie **1** car $k = 0$.

• **`parmi(1,2)`** renvoie **`parmi(1,1)+ parmi(0,1)`** c'est-à-dire **2**.

b) • **`parmi(2,2)`** renvoie **1** car $k = n$.

• **`parmi(0,2)`** renvoie **1** car $k = 0$.

• **`parmi(2,3)`** renvoie **`parmi(2,2)+ parmi(1,2)`** c'est-à-dire **3**.

• **`parmi(1,3)`** renvoie **`parmi(1,2)+ parmi(0,2)`** c'est-à-dire **3**.

c) **`parmi(2,4)`** renvoie **`parmi(2,3)+ parmi(1,3)`** c'est-à-dire **6**.

Dans tous les cas, les valeurs sont égales.
Donc on peut conjecturer que :

`parmi(k,n)` renvoie $\binom{n}{k}$.

2. $\binom{n}{0} = \binom{n}{n} = 1$ et $\binom{n}{k} = \binom{n-1}{k} + \binom{n-1}{k-1}$

3.

```
# def parmi(k,n):
#   if k==0 or n==k:
#       a=1
#   else:
#       a=parmi(k,n-1)+parmi(k-1,n-1)
#   return a

def f(n):
    fact=1
    if n!=0:
        for i in range(1,n+1):
            fact=fact*i
    return fact
def parmi(k,n):
    return f(n)/(f(k)*f(n-k))
def proba_bin(p,n,k):
    return parmi(k,n)*(p**k)*(1-p)**(n-k)
```

4.

```
def seuil_bin(s,p,n):
    k=0
    prob=proba_bin(p,n,0)
    while prob<s:
        k=k+1
        prob=prob+proba_bin(p,n,k)
    return k
```

B ▶ 1. Soit X la variable aléatoire donnant le nombre de personnes venant effectivement au gala et k le nombre minimal de repas à prévoir.

X suit la loi binomiale de paramètres $n = 400$ et $p = 0{,}74$ et k est le plus petit entier tel que $p(X \leqslant k) \geqslant 0{,}95$ qui est donc donné par **`seuil_bin(0.95,0.74,400)`** qui donne **310**.

2. **`seuil_bin(0.99,0.74,400)`** qui donne **316**.

C ▶ 1.

```
def proba_cum_bin(p,n,k):
    proba=0
    for i in range(k+1):
        proba=proba+proba_bin(p,n,i)
    return proba
def seuil_bin2(s,p,k):
    n=k
    while proba_cum_bin(p,n,k)>=s:
        n=n+1
    return n-1
```

2. Soit Y la variable aléatoire donnant le nombre de personnes venant effectivement au gala et n le nombre d'invitations à envoyer.

Y suit la loi binomiale de paramètres n et $p = 0{,}74$ et on cherche la plus grande valeur de n telle que $p(X \leqslant 250) \geqslant 0{,}95$ qui est donc donnée par **`seuil_bin2(0.95,0.74,250)`** qui donne **321**.

5. TP Sondage et temps avant l'élection

- **Durée estimée :** 30 min
- **Objectif :** Discuter des conditions de réalisation et des résultats d'un sondage.

1. M. Valls ne s'est finalement pas présenté donc le pourcentage d'intention de votes en sa faveur n'a pas grand intérêt.

2. a) • M. Valls : entre 10 % et 16 %

• J.-L. Mélenchon : entre 11 % et 17 %

• E. Macron : entre 11 % et 17 %

• F. Fillon : entre 21 % et 27 %

• M. Le Pen : entre 21 % et 27 %

b) • J.-L. Mélenchon a obtenu 19,6 % des suffrages exprimés, c'est au-dessus de 17 % qui était la fourchette haute pour lui.

• E. Macron a obtenu 24 % des suffrages exprimés, c'est au-dessus de 17 % qui était la fourchette haute pour lui.

• F. Fillon a obtenu 20 % des suffrages exprimés, c'est légèrement en dessous de 21 % qui était la fourchette basse pour lui.

• M. Le Pen a obtenu 21,3 % des suffrages exprimés ce qui est bien entre 21 % et 27 %.

On constate que, pour la plupart des candidats, les résultats annoncés par ces sondages sont inexacts, même en tenant compte de la marge d'erreur.

c) Les intentions de votes données pour ce sondage sont beaucoup plus proches des résultats finaux.

3. On constate que l'information apportée par un sondage réalisé 6 mois avant l'élection est assez faible. Elle est de bien meilleure qualité pour un sondage réalisé juste avant et qui a donc plus d'intérêt.

6. TP Sondage et suffrage indirect

- **Durée estimée :** 30 min
- **Objectif :** Discuter des résultats d'un sondage dans une élection au suffrage indirect.

1. a) D. Trump a gagné l'élection, on peut donc, en première approche, penser que ce sondage se trompe.

b) • $\dfrac{65\,853\,514}{136\,669\,276} \approx 0{,}48$

donc 48 % des votes environ pour H. Clinton.

• $\dfrac{62\,984\,828}{136\,669\,276} \approx 0{,}46$

donc 46 % des votes environ pour D. Trump.

On obtient finalement des scores proches des résultats annoncés par le sondage.

c) Non, car autrement, H. Clinton aurait été gagnante (ou il y aurait eu un deuxième tour).

2. b) Avec les formules `=SOMME(B2:B52)` et `=SOMME(C2:C52)`, on obtient qu'il y a 308,7 millions d'habitants aux États-Unis et 538 grands électeurs.

c) On écrit `=C2/B2` en D2 et on recopie vers le bas.

f) Cela « suffit » car si l'on fait la somme du nombre de grands électeurs de ces états, on obtient 271 grands électeurs d'après le tableur, soit plus de la moitié.

g) La formule `=SOMME(B2:B41)` permet de déterminer qu'il y a 135 millions d'habitants dans ces 40 états.

h) Finalement, on voit qu'il suffirait (c'est une situation extrême pour illustrer le propos) d'obtenir la moitié des voix dans les 40 états donnés précédemment pour gagner l'élection soit 67,5 millions d'habitants.

Comme $\frac{67,5}{308,7} \approx 0,22$ soit 22 %, cela veut dire qu'avec l'adhésion de 22 % de la population des États-Unis, on peut gagner l'élection !

Un sondage sur les intentions de votes nationales pour des candidats ne donne donc aucune information sur le résultat final.

7. TP Sondage et marge d'erreur

- **Durée estimée :** 30 min
- **Objectif :** Discuter des conditions de réalisation et des résultats d'un sondage.

1. On constate que sur un sondage portant sur 5 000 personnes, pour un candidat ayant 25 % d'intention de votes, la marge d'erreur est de 1,2 %.
Soit entre 25 % – 1,2 % = 23,8 %
et 25 % + 1,2 % = 26,2 %.

2. • Pour E. Macron : on prend la ligne correspondant à des échantillons de 5 000 personnes pour un pourcentage de 65 % (valeur la plus proche de 63 %).
On obtient une marge d'erreur de 1,3 % soit entre 61,7 % et 64,3 %.

• Pour M. Le Pen : on prend la ligne correspondant à des échantillons de 5 000 personnes pour un pourcentage de 35 % (valeur la plus proche de 37 %).
On obtient une marge d'erreur de 1,3 % soit entre 35,7 % et 38,3 %.

Les résultats de ces élections ont été 66,1 % pour E. Macron et 33,9 % pour M. Le Pen donc on constate que ceux de E. Macron ont été sous-estimés et que ceux de M. Le Pen ont été surestimés (même en tenant compte de la marge d'erreur).

3. a) Par exemple, pour n = 1 000 et f = 0,2. Le tableau donne 2,5 % de marge d'erreur.

La formule donne :

$$2\sqrt{\frac{f(1-f)}{n}} = 2\sqrt{\frac{0,2 \times 0,8}{1\,000}} \approx 0,025 \text{ soit } 2,5\ \%$$

On retrouve donc les mêmes résultats.

b) Cette formule s'applique dans le cas d'un tirage aléatoire avec remise, c'est-à-dire que pour obtenir un échantillon représentatif, il faudrait tirer n personnes au hasard avec remise dans l'ensemble de la population des inscrits.

En réalité, dans une grande population comme les inscrits qui compte plusieurs dizaines de millions de personnes, le fait que le tirage soit avec remise ou non a peu d'impact et la formule donnée reste valable.

En revanche, quand on ne fait plus un tirage réellement aléatoire dans la population, ce qui est le cas de la méthode des quotas où les sondeurs essaient de reproduire les caractéristiques de la population (en termes de sexe, d'âges, de situation professionnelle, etc.), il n'y a plus de formule permettant d'estimer la marge d'erreur mais les sondeurs considèrent que la formule précédente s'applique : c'est le sens de la phrase de l'énoncé.